

# 清华大学学位论文 L<sup>A</sup>T<sub>E</sub>X 模板

## 使用示例文档 v5.4.3

(申请清华大学工学硕士学位论文)

培 养 单 位: 计 算 机 科 学 与 技 术 系

学 科: 计 算 机 科 学 与 技 术

研 究 生: 梁 锡 豪

指 导 教 师: 徐 明 星 副 教 授

二〇一九年三月



# **An Introduction to L<sup>A</sup>T<sub>E</sub>X Thesis Template of Tsinghua University v5.4.3**

Thesis Submitted to  
**Tsinghua University**  
in partial fulfillment of the requirement  
for the professional degree of  
**Doctor of Engineering**

by  
**Liang Xihao**  
( **Computer Science and Technology** )

Thesis Supervisor : Professor Xu Mingxing

**March, 2019**



# 关于学位论文使用授权的说明

本人完全了解清华大学有关保留、使用学位论文的规定，即：

清华大学拥有在著作权法规定范围内学位论文的使用权，其中包括：(1) 已获学位的研究生必须按学校规定提交学位论文，学校可以采用影印、缩印或其他复制手段保存研究生上交的学位论文；(2) 为教学和科研目的，学校可以将公开的学位论文作为资料在图书馆、资料室等场所供校内师生阅读，或在校园网上供校内师生浏览部分内容。

本人保证遵守上述规定。

**(保密的论文在解密后应遵守此规定)**

作者签名：\_\_\_\_\_

导师签名：\_\_\_\_\_

日 期：\_\_\_\_\_

日 期：\_\_\_\_\_



## 摘 要

自 Web2.0 普及后，人们习惯在互联网的各种平台上透过不同的媒体来分享和传递他们的想法和情感。透过对这些媒体进行情感分析，我们可以得知人们的想法和态度。譬如透过分析产品评论了解用户对新产品是否满意，又或者分析社交平台上的舆论了解网民对新政策是否同意，以此快速响应，其中蕴含着丰富的商业价值和政治价值，其相关技术的研究价值在近年也得到了重视。而文本作为较常见的媒体之一，加之部分微博等社交平台推出了用户生产数据的采集服务，提供了充裕的文本数据资源，面向文本的情感识别研究得以更快的速度发展。然而随着在互联网上的交互方式变得丰富，文本的数据结构也变得多种多样，如微博上的短文本、在线实时聊天的两人或多人对话、讨论区里的帖子回复。在处理不同数据结构时，该如何提取当中的信息并加以运用来预测目标结果，成为了重要的研究课题。

本文主要探讨了两个不同数据结构下的情感识别问题，并提出了一个通用的文本情感识别系统设计方案。论文的主要内容如下：

- 面向微博的反讽识别。反讽作为一种特殊的修辞手法，起着把文本字面意思反转的效果。识别文本中反讽修辞的使用对于正确理解发言者的意图起着关键性的作用。本文研究了在微博中识别反讽的出现以及其对应类型，深入了解实验数据当中各个类型的样本的特性，分析单个分类器对各个类的识别能力，给出一个基于集成学习的反讽识别框架，以此在多个独立分类器的基础上实现一个集成系统来达到更好的识别能力。
- 面向三轮对话的情感识别。为了更好地识别一段文本的情感，引入上下文信息被认为有指导性作用。而在文本对话的场景下，要识别某个人在某次发言所表达的情感，可以考虑引入该次聊天的历史记录。本文研究了在两人轮流发言的三轮对话中，识别最后一轮发言所表达的情感。此处采用与面向微博的反讽识别相同的系统设计以评估设计方案的泛用性，另外我们进一步探索了上下文信息的运用方面，透过把不同的运用方面体现在分类器的不同设计方案上，并根据其性能差别和对神经网络权重的分析，了解上下文信息如何有助于识别正文的情感。

**关键词：**意图识别；情感分析；反讽识别；深度学习，集成学习

## **Abstract**

An abstract of a dissertation is a summary and extraction of research work and contributions. Included in an abstract should be description of research topic and research objective, brief introduction to methodology and research process, and summarization of conclusion and contributions of the research. An abstract should be characterized by independence and clarity and carry identical information with the dissertation. It should be such that the general idea and major contributions of the dissertation are conveyed without reading the dissertation.

An abstract should be concise and to the point. It is a misunderstanding to make an abstract an outline of the dissertation and words “the first chapter”, “the second chapter” and the like should be avoided in the abstract.

Key words are terms used in a dissertation for indexing, reflecting core information of the dissertation. An abstract may contain a maximum of 5 key words, with semi-colons used in between to separate one another.

**Key words:** Opinion mining; sentiment analysis; irony detection; deep learning; ensemble learning



# 目 录

<b>第 1 章 引言</b>	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 情感模型	2
1.2.2 情感识别	3
1.2.3 反讽识别	6
1.2.4 社交媒体上的文本意图识别	7
1.3 存在的问题	8
1.4 本论文的内容安排	9
<b>第 2 章 问题分析和研究框架</b>	11
2.1 本章引论	11
2.2 问题分析	11
2.3 研究框架	13
2.3.1 框架入口	13
2.3.2 基础分类器	13
2.3.3 集成识别系统	14
2.4 本章小结	14
<b>第 3 章 意图识别技术</b>	15
3.1 本章引论	15
3.2 文本预处理	15
3.2.1 分词	15
3.2.2 拼写修正	16
3.2.3 规范化	17
3.3 特征提取	17
3.3.1 词嵌入	17
3.3.2 词汇特征	17
3.3.3 句法特征	17
3.3.4 语义特征	17
3.3.5 基于人工神经网络	17
3.4 分类算法	17

3.4.1 传统机器学习方法 .....	17
3.4.2 深度学习方法 .....	17
3.5 集成学习 .....	17
3.6 本章小结 .....	17
插图索引 .....	18
表格索引 .....	19
公式索引 .....	20
参考文献 .....	21
致 谢 .....	24
声 明 .....	25
附录 A 外文资料原文 .....	26
A.1 Single-Objective Programming .....	26
A.1.1 Linear Programming .....	27
A.1.2 Nonlinear Programming .....	28
A.1.3 Integer Programming .....	29
附录 B 外文资料的调研阅读报告或书面翻译 .....	30
B.1 单目标规划 .....	30
B.1.1 线性规划 .....	30
B.1.2 非线性规划 .....	31
B.1.3 整数规划 .....	31
附录 C 其它附录 .....	32
个人简历、在学期间发表的学术论文与研究成果 .....	33

## 主要符号对照表

HPC	高性能计算 (High Performance Computing)
cluster	集群
Itanium	安腾
SMP	对称多处理
API	应用程序编程接口
PI	聚酰亚胺
MPI	聚酰亚胺模型化合物, N-苯基邻苯酰亚胺
PBI	聚苯并咪唑
MPBI	聚苯并咪唑模型化合物, N-苯基苯并咪唑
PY	聚吡咙
PMDA-BDA	均苯四酸二酐与联苯四胺合成的聚吡咙薄膜
$\Delta G$	活化自由能 (Activation Free Energy)
$\chi$	传输系数 (Transmission Coefficient)
$E$	能量
$m$	质量
$c$	光速
$P$	概率
$T$	时间
$v$	速度
劝学	<p>君子曰：学不可以已。青，取之于蓝，而青于蓝；冰，水为之，而寒于水。木直中绳。輅以为轮，其曲中规。虽有槁暴，不复挺者，輅使之然也。故木受绳则直，金就砺则利，君子博学而日参省乎己，则知明而行无过矣。吾尝终日而思矣，不如须臾之所学也；吾尝跂而望矣，不如登高之博见也。登高而招，臂非加长也，而见者远；顺风而呼，声非加疾也，而闻者彰。假舆马者，非利足也，而致千里；假舟楫者，非能水也，而绝江河，君子生非异也，善假于物也。积土成山，风雨兴焉；积水成渊，蛟龙生焉；积善成德，而神明自得，圣心备焉。故不积跬步，无以至千里；不积小流，无以成江海。骐驎一跃，不能十步；弩马十驾，功在不舍。锲而舍之，朽木不折；锲而不舍，金石可镂。蚓无爪牙之利，筋骨之强，上食埃土，下饮黄泉，用心一也。蟹</p>

六跪而二螯，非蛇鱗之穴无可寄托者，用心躁也。——荀况

## 第1章 引言

### 1.1 研究背景与意义

意图识别旨在了解人们对特定事件或实体的想法、态度和情感。自 Web2.0 普及后,大量网民每天在互联网生产着不同媒体类型的数据,其中包含各种信息,如个人生活经历,购买行为,对产品服务的体验评价,对社会时事的看法等等。从人们的日常社交需求来看,这种借由互联网媒体的分享非常便捷,我们可以了解到亲朋好友的近况,也或者随时和不认识的网民交流对具体事件的想法。在商业上,借由对用户的网络行为进行分析,企业可以对应客户或者潜在客户有更深入的了解,对他们的需求和反馈及时作出反应将带来战略性的优势。在社会管理上,政府可以透过对网民在网络上的发言了解人民的想法和舆论的走向,进而作出相应的措施。正因为互联网的普及,才使得以上基于对特定人群的了解来进行决策的做法成为可能。随着数据资源变得丰富,相应的技术在近年有明显的发展,目前市面上已经有公司(如国内的腾讯和阿里巴巴,以及国外的微软和亚马逊等)提供基于大型社交媒体平台(如微博,讨论区等)上的数据进行意图分析相关的规范化服务,然而相应的技术依然有进步空间,研究工作还在不同方向上摸索。

情感在人们的思想表达和交流中起着重要作用<sup>[1]</sup>,比起了解该想法的细节内容,情感对应该想法的大体倾向。譬如在分析用户对新产品的评论时,从对正负性情感反馈的统计可以得知新产品是否能让大部分的客户满意,或者筛选出表示不满意的用户再进行深入分析,因此情感识别是意图分析中属于非常重要的一环。而由于在互联网上,大部分情况下用户以文本表达想法,面向文本的意图识别成为了近年的最要研究课题之一。相对于人们面对面交流的场景,聆听者可以根据发言者的肢体语言,面部表情以及声调变化等额外提示更好地理解发言者所表达的内容,然而这些信息并不存在于文本当中,这也正是对文本进行情感识别本身的难点之一<sup>[2]</sup>。

反讽的修辞手法在意图识别当中起着特殊的影响。Henry Watson Fowler 在《The King's English》一书中描述“即使对反讽的定义有数百种,其中只有包含‘表面意思和实际意思不同’这个概念的才能被接受”。Eric Partridge 在《Usage and Abusage》一书中指出“反讽存在于所表达意思的另一面”。总的多说当反讽在文本中出现,那么文本所表达的意思应该和字面表达的意思完全相反。譬如某人表示“我就喜欢你不断挑战我的底线”,从字面上理解应倾向于正面情感,然而根据常识可知“挑战底线”是一种让人反感的行为,与“喜欢”相矛盾。这段文字实则暗示发言者的“底线”

正被“你”“挑战”，表达的是负面情感。因此在意图识别和情感分析当中，正确检查出反讽的使用能够避免对内容的错误理解。

## 1.2 国内外研究现状

### 1.2.1 情感模型

情感计算的基础是对情感作出描述，现有的描述方式可以分成两个大类：范畴观和维度观。范畴观即把不同情感对应到一组离散的情感标签上 Alm 等人<sup>[3]</sup>，其中具代表性的有 Plutchik 的情感模型<sup>[4]</sup>和 Ekan 的情感理论<sup>[5]</sup>和。Plutchik 的情感模型包含十种情感：愤怒、恐惧、悲伤、厌恶、期待、信任、高兴、惊讶；这些情感都各自对应具有重要生存意义的行为，各种复杂的情感都是由这此基本情感构成，另外这十种情感可以分成五组对立的情感对。Ekan 在十年后提出的情感理论和 Plutchik 的相似，但相对地少了期待和信任，是一个六类情感模型。




图 1.1 Plutchik<sup>[4]</sup> 提出的情感轮模型

以维度观描述情感就是把情感映射到多维空间的点上，而目前维度观情感模型以二维和三维空间的为主。二维情感模型中较有代表性的是 Russell 提出的环状模型 (Circumplex Model)<sup>[6]</sup>，其中纵坐标对应情感的激活度 (Arousal)，横坐标对应情感向性 (Valence)，而不同的情感则分布在一个环状的区域内。Bradley 等人<sup>[7]</sup>提出的向量模型 (Vector Model) 对横轴和纵轴的定义相似，但其理论假设高激活度的情感应该有较明显的正向或负向，相对地低激活度的情感则偏向中性，故

情感分布在一个回力标形状的区域。Watson 和 Tellegen<sup>[8]</sup> 提出的 PANA (positive activation-negative activation) 模型和前两者在理论上则有明显的不同，他们认为情感的正面作用和负面作用是两个独立的成分，所以在模型中纵轴和横轴分别表示情感正面作用和负面作用的强弱，其效果相当于把 Russell 等人提出的环状模型的向量空间旋转 45 度<sup>[9]</sup>。

基于三维空间的情感模型中具有代表性的有 Plutchik<sup>[4]</sup> 提出的情感轮模型，Plutchik 认为情绪之间包含强度，相似性和两极性三种维度，椎体的顶部和底部分别对应强的情绪和弱的情绪，相似的情感对应椎体中相近的位置，对立的情绪则会对应到椎体中对立的位置上。另外还有 Mehrabian<sup>[10]</sup> 提出的 PAD 模型，其三维空间的三个坐标轴分别对应情感愉悦度 (Pleasure)、激活度 (Arousal) 以及优势度 (Dominance)。较近期被提出的是 Hugo<sup>[11]</sup> 的情感立方体模型，其三维空间的三个坐标轴分别对应 5-羟色胺 (5-hydroxytryptamine, 5-HT)，多巴胺 (dopamine, DA) 和去甲肾上腺素 (noradrenaline, NE) 三种神经递质所产生信号的强弱，并对空间中一个立方体的八个顶点标记了其对应的情感。




图 1.2 Hugo<sup>[11]</sup> 的情感立方体模型

### 1.2.2 情感识别

对应上述情感模型的分类，情感识别研究可以分成两类。第一类对应范畴观，给定一组情感类型，判断一段文本或针对文本内的某个方面所表达的情感倾向于该组情感中的哪一个，或者是否包含这一组情感中的一个或多个情感。如国际比赛 SemEval2018<sup>[12]</sup> 任务一的子任务要求识别一段微博中是否包含愤怒、恐惧、悲

伤等十一种情感中的一种或多种情感。另一类情感识别研究对应维度观，对于给定的情感属性，判断一段文本中该情感属性的强度。其中常见的有情感向性的二分类问题（正性或负性）、三分类问题（正性、中性或负性）、五分类问题（非常正性，正性、中性、负性或非常负性）。其中五分类问题的研究对象一般是互联网上五星评分制的产品评论或者电影评论等。而对目前文本情感识别的研究按照文本的粒度可以大致分成三类：文章级别，句子级别，属性级别。

在文章级别的情感识别中，虽然一篇文章由多个句子组成，均假设其整体存在某种情感偏向，而研究目标则是自动识别出该种情感偏向的类型或强度。Turney<sup>[13]</sup>利用线上电影评论中"推荐"（大拇指朝上）和"不推荐"（大拇指朝下）的标记研究对电影评论的正负性情感识别。他提出利用点互信息 (Pointwise Mutual Information, PMI) 来评估单词的语义倾向性，其中 PMI 透过在大型语料库中统计两个单词的共同出现的情况来评估两个单词的相似度。首先利用 PMI 值评估各个单词与正向情感的代表性单词"excellent" 和负向情感的代表性单词"poor" 的相似性，再取这两个 PMI 值作差得出该单词在语义上倾向于哪一种情感。最近透过计算整段评论的平均语义倾向性评估整体的情感倾向。Pang 和 Lee<sup>[14]</sup> 采用了不同的方法研究相同的问题。他们首先对评论中每个句子的主观程度进行评分，利用评分构造一个带权重的句子关系图，再基于最小割算法结合上下文加强对每个句子主观程度的判断，过滤评论中不带主观情感的句子后再判断整个评论的情感向性，以此加增强了识别能力。Tang 等人<sup>[15]</sup> 则研究了产品评论的五级评分预测。除了评论的文本内容，他们进一步引入了用户的信息和产品的信息。经过数据分析，他们发现相同用户对不同产品（此处对应电影）的评论和评分较不同用户之间的一致，另外不同用户对同一产品的评论和评分较不同产品之间的一致，这显示了用户和产品各自都存在一些相对固定的属性。因此 Tang 等人提出一种对用户和产品提取语义特征的方法，并应用于评论的五级评分预测。实验结果显示他们的方法在多个数据集上达到了较好的性能，这同时引出了加入背景信息来加强系统识别能力的可能性。

然而一篇文章有可能同时表达了多种观点和情感，因此有另一类研究针对句子或短文本所表达的情感，即句子级别的情感识别。由于句子的文本长度较文章的短，文本内部的逻辑较简单，但相对地所包含的提示信息也较少，课题的难点与前者有所不同。Khan 等人<sup>[16]</sup> 研究了对线上评论中句子进行正负性情感识别。他们首先区分出评论中各个句子的主观性和客观性，然后针对带主观情感的句子，利用开源自然语言工具 SentiWordNet 获取各个单词的正负情感属性，再根据句子的词性标注和他们设计的规则计算整个句子的情感向性。他们的研究默认单词的正负情感属性在不同场景下不变，然而 Li 等人<sup>[17]</sup> 指出部分单词在特定场景下会有



不同的情感向性，因此他们提出了一种有监督学习方法，自动学习各单词在指定领域下的情感向性，以此作为文本的特征，并应用于对产品评论的情感识别中。实验结果显示使用 SentiWordNet 提供的全局情感评分和针对领域评估的情感评分相比，后者的识别性能力更好，同时验证了他们的假设。一些研究则选择端到端地学习单词的情感和语义倾向，在 Santos 和 Gatti<sup>[18]</sup> 对电影评论和微博的情感识别研究中，他们提出了利用卷积神经网络分别从字符级别和词级别计算出单词对应的特征向量，然后同样以卷积神经网络结合句子中各单词的向量得出句子的表示向量和预测整体的情感倾向。结果显示他们的方法较早期的其他方法性能更好。

在一些应用场景当中，我们希望了解发言者对某个特定对象或者它的某个特定属性的想法。譬如新手机推出市场后，厂商需要了解用户对手机的续航能力，拍照质量，交互体验等各方面的评价，对于评论中同时谈论手机的多个方面并且好评和差评不一时，应该针对各个属性分别识别发言者所表达的感情，因此有了属性级别的情感识别。Che 等人<sup>[19]</sup> 提出一种句子压缩算法，透过对句子进行依存句法分析，过滤与目标属性的情感无关的内容。他们采用了多种语义和语法特征作为输入，以条件随机场 (Conditional random field, CRF) 作为分类器。实验结果显示过滤掉不相关的文本部分后，识别性能有所提升。Wang 等人<sup>[20]</sup> 研究了对网上评论中特定实体或属性的情感识别。他们提出了一个基于注意力机制的长短期记忆网络 (Long Short-Term Memory, LSTM)，特点在于只以词向量作为输入，而不采用其他传统的语义和语法特征，另外利用注意力机制自动识别与目标相关的内容。他们实验基于国际比赛 SemEval-2014 任务四<sup>[21]</sup> 中的一个子任务，结果然显示他们的系统性能达到了当时的技术水平。另外透过对注意力单元的输出进行分析，验证了注意力机制能有效识别文本中与目标相关的内容。Tang 等人<sup>[22]</sup> 分别前述数据集中电脑和餐厅相关的两组样本进行属性级别的情感识别，但有别于当时主流的以特征提取为主的浅层机器学习方法（如支持向量机）和针对序列的深度学习模型（如循环神经网络），他们提出了一个基于注意力机制的深度记忆网络。另外针对文本中各个单词和目标单词在句子中的距离，作者引入了距离信息提出了注意力单元的多种变形。实验结果显示他们提出的深度记忆网络达到了当时最优的系统（手工特征结合支持向量机）的性能。另外对注意力单元的中间结果进行人工分析，验证了在同一段评论中，引入距离信息的注意力单元有助于区分不同单词对不同目标的情感的贡献。

### 1.2.3 反讽识别

反讽识别技术作为很多自然语言系统的一部分，其应用场景有线上评论分析，人机对话等，对正确理解评论的情感倾向和话语的意图起着辅助的作用。**Tsur** 等人<sup>[23][24]</sup> 研究了对微博平台 **Twitter** 上的微博以及电商平台亚马逊上的评论进行反讽强度的识别，按明显不含反讽和明显表示反讽分成五级，由人工进行标注。他们提出的 **SASI** 算法分别从文本提取了词频相关的模式特征以及基于标点符号的特征，以 **K** 最近邻算法作为分类器。另外利用在 **Twitter** 按井号标签 **#sarcastic** 自动爬取了额外的反讽语料用于初步的模型训练。对实验结果的比较证明了各种特征的有效性以及添加额外语料对模型训练的帮助。

为了以较低成本获取大量的反讽语料，很多研究从微博平台根据井号标签自动筛选出可能带反讽的微博。**Reyes** 等人<sup>[25]</sup> 利用 **#irony, #education, #humor, #politics** 在 **Twitter** 上自动获取四组英语微博，并把 **#irony** 对应的微博和另外三组微博两两组成二分类实验。他们提出了四个方面的文本特征以及对应的提取方法，包括：特殊标记（词汇和标点符号等）、不可预期性、表达风格、情感特性；并比较了每项特征在各组微博中的出现情况，显示了与反讽类微博的相关性。另外分别采用朴素贝叶斯和决策树作为分类器，但没有明显的性能区别。

类似的数据收集方法对其他语言同样适用。**Kunneman** 等人<sup>[26]</sup> 则利用对应的德语井号标签来获取反讽语料，以此研究德语微博中的反讽识别。他们取 **N** 元语法作为输入特征，以 **Balanced Winnow**<sup>[27]</sup> 作为分类器，在测试集上达到约 **0.85** 的召回率和 **0.87** 的 **AUC** 值。但他们进一步经过人工检验评估了基于井号标签自动标注的有效性，分析结果显示该方法获取的反讽样本中包含约 **10**

有别于早期以手动设计的特征作为输入和以非神经网络的机器学习方法建模，**Poria** 等人<sup>[28]</sup> 首次将神经网络应用于对微博的反讽识别。他们的算法框架主要包含四个卷积神经网络，并分别利用不同的数据集进行预训练，分别对应反讽识别、情感极性识别、情感类型识别和性格识别。最后取四个卷积神经网络的中间结果作为特征，利用支持向量机 (**Support Vector Machine, SVM**) 进行后融后得出最终预测结果。实验显示引入反讽识别以外的三个语料库提升了系统的识别能力。



图 1.3 引入多个领域信息的反讽识别神经网络模型，引自 [28]

### 1.2.4 社交媒体上的文本意图识别

随着社交媒体的普及，网民们习惯于在微博，讨论区等平台上表达个人意见和互相讨论。有别于新闻或学术材料等较正式的文件，网民可以较随心所欲地发言，社交媒体因此成为了意图识别的重要研究对象之一。但和一些产品评论或文章等文本类型不同，社交媒体上的文本普遍较短<sup>[29]</sup>，缺少对背景信息的提示，难以判断其内容所属的领域，这对正确理解其表达的想法造成困难。另外语言的使用有别于正式的用法，在中文微博中会出现新的短语或对旧短语有新的解释<sup>[30]</sup>，如“锦鲤”暗示“好运”，“灌水”表示“发表没有意义的内容”，在英文微博中会出现错拼字、非正式缩略语、表情符<sup>[31][32]</sup>，如“tnx”对应英文单词“thanks”，“:)”表示微笑等。虽然没有正式的语言组织对这些新的用法进行整合，但因为这些新用法更方便或对思想的表达更丰富到位，随着在网络上的传播而在网民之间达成了共识。传统的文本特征提取建立在单词标准用法和正规的语法分析基础上，而由于新词汇和新用法的出现，会出现词汇的意思无法被识别或被错误理解，这对于透过人工智能来理解文本成为了一大难点。因此有别于传统的文本研究，在面向社交媒体的文本意图识别时，需要采用额外手段对文本进行预处理进行规范化，或透过大量语料尝试自动学习其语言属性。

Khan 等人<sup>[33]</sup>研究了微博的正负中性情感识别。他们提出了一个混合三个分类器的情感识别框架来解决数据稀疏的问题，以此提高整体的分类性能。另外还提出了一组针对微博文本的预处理步骤，其中包括俚语和缩略语分析，词干提取，拼写检查和修正，用户名和井号标签移除等。他们的系统在 6 个微博数据集上达

到了平均 83.3% 的 F1 值以及平均 85.7% 的准确率，和同类型技术比较后验证了他们系统以及预处理手段的有效性。

Angiani 等人<sup>[34]</sup> 针对英语微博比较了其种常用的文本预处理技术对情感分析的影响，其中包括单词的规范化、表情符到情感标签的映射、俚语映射、词干提取、停词过滤等。分析显示除了俚语映射以外，其他技术均对情感识别有正面影响，其中部分技术有助于统一拼写相似的单汇，以此关联相同概念的词组。但同时采用所以预处理技术并不保证达到最好的效果，作者指出依然需要根据应用场景和文本的特性做选择。




图 1.4 基于卷积神经网络的微博情感分类模型，引自<sup>[35]</sup>

张海涛等人<sup>[35]</sup> 则研究了中文微博和评论中的文本情感分类。他们针对当时微博上具有一定争议特定话题 # 打呼噜被室友群殴 # 收集数据，确保了样本围绕同一个主题并且有充足的数据量。使用开源工具 NLPIR/ICTCLAS2016 对语料进行分词，再以词向量学习算法 word2vec 从语料中学习词的表示向量作为输入，以基于卷积神经网络的模型作为分类器，另外以支持向量机作为对照算法。实验结果显示在面向原创微博等略长文本的情感识别时，他们的系统比支持向量机性能更好，而面向短文本时则相反。

### 1.3 存在的问题

由于近年来各企业或机构对意图识别的需求增加，相关技术的研究备受关注，加上深度学习的快速发展，情感识别和反讽识别的性能水平也在逐年提升。然而相关研究依然存在一些空白部分值得进一步探索：

- **对不同数据结构的处理。** 受限于互联网上文本的呈现方式以及数据的收集方式，早期的大部分面向文本的意图识别以文章、微博、评论等形式的数据作为研究对象。随着社交平台功能加强，除了研究的对象本身，我们能获取更多相关的背景信息。以微博平台为例，除了微博的文本内容以外，我们能

根据其历史上发布过的内容分析用户的性格和语言使用习惯，另外可以根据微博下的评论加强对微博本文的了解。但相对地，数据结构变得复杂，该如何从中提取特征，该如何对不同信息之间的相互关系建模，这些问题都有值得尝试的空间。

- **针对优化目标的系统调整。**在不同的使用场景下，针对不同的应用目标，我们会采用不同指标来评估系统的识别水平，并以提高该指标为目标对系统进行优化。而对一个指标的加强往往会导致另一个指标的下降，在数据分布不均匀的分类问题当中，这一影响尤其明显。譬如在反讽识别当中，由于微博上包含反讽的微博明显较不含反讽的微博少，若以准确率作为优化指标，整个系统会倾向将微博判断为不含反讽，含反讽的微博召回率会较低。若改以召回率作为优化指标，整个系统会倾向将微博判断为包含反讽，但因为不含反讽的微博比例较高，会把大量不含反讽的微博误判为包含反讽。近年的相关研究的重点以特征提取、深度学习建模、迁移学习等方向为主，在给定在相同的训练数据以及相同的模型框架下，模型的拟合能力是有限的，如何针对不同的优化目标对系统进行调整是个极少被探讨的问题。

## 1.4 本论文的内容安排

本文提出了一个面向文本意图识别的系统设计方案，并将其应用于两个数据结构不同的意图识别问题：面向微博的反讽识别、面向三轮对话的情感识别。论文的工作主要围绕我们提出的系统设计方案和这两个应用场景展开。

在论文的第二章，我们会对面向文本的意图识别一类的问题作出分析，并给出一个统一的数学定义。基于该定义，我们将给出一个通用的意图识别系统框架，细节说明其中每个模块的功能和目的。该框架将被具体应用到后面章节的实验当中。

在第三章，我们会介绍在意图识别系统中使用到的自然语言处理技术和意图识别技术，并对应到前一章描述的系统框架的各个模块当中。我们会对后续实验中使用到的技术给出相对充分的说明，同时也会相关的技术给出概要的描述，以便于其他研究者在本论文未深入探索的方向作出拓展性的研究。

第四章中，我们将把前述的系统框架和技术应用于面向微博的反讽识别，透过对数据的特性进行人工分析，我们将给出具体的反讽识别系统实验方案，透过对细节的调整和性能的比较，验证我们采用的策略的效果并分析其中的原因。整个实验基于国际比赛 SemEval2018 的任务三<sup>[36]</sup>，其中包含两个子任务。子任务一为二分类问题，要求识别微博是否包含反讽的修辞手法。另一个子任务为四分类

问题，数据与子任务一相同，但原本"反讽"一类的样本被细分成反讽的三个类型：基于相反语义的言语反讽、其他言语反讽、情景反讽。我们将采用官方提供的训练数据和测试数据，并按照比赛的要求开发识别系统，以此和其他参赛系统的性能进行比较，评估我们系统的整理水平。另外透过对错判的样本进行人工检查来进行错误分析，尝试给出系统对该问题的改进方向。

在第五章中，我们将采用与前一章相同的流程来研究面向三轮对话的情感识别。本章的实验基于国际比赛 **SemEval2019** 的任务三<sup>[2]</sup>，比赛要求参赛系统识别两人轮流发言的三轮对话中最后一轮发言者所表达的情感，一共四个情感类别：高兴、悲伤、愤怒，其他。除了如前一章中验证系统框架的有效性以外，本章我们将深入分析复杂文本数据结构的不同建模方法对系统最终识别能力的影响，并透过对网络权重和中间结果的分析了解上下文中哪些信息对最终的情感识别起著作用，以及神经网络是否能捕捉到文本对情感识别起关键作用的成分。

## 第2章 问题分析和研究框架

### 2.1 本章引论

随着互联网上不同类型的平台出现,人们每天在各种平台上产生着各种各样的行为和发言。如现在微博平台上会对热门时事设置井号标签,人们透过加上对应标签来表达对该事件的想法,以及透过对这些发言进行赞点、分享或评论来表达支持或反驳。利用井号标签收集数据并进行意图分析可以得知网民对该事件的舆论方向。在其他平台上的各种行为记录同样可能有挖掘其意图的价值,意图识别的应用场景也变得多种多样,但即使数据的内容和结构不同,问题的本质是相似的。因此在本章,我们将首先针对意图识别进行分析,并给出统一的形式化表示。

再进一步,基于该形式化表示,我们提出一个面向社交媒体文本的意图识别研究框架。从原始文本的输入到最终识别目标的输出,理清其中每个步骤的功能和目的,给出一个完整识别系统的设计方案,为解决后续章节中研究的问题准备一个统一的切入点。

### 2.2 问题分析

本小节中,我们将对意图识别中涉及的各个元素作出分析,并给出统一的形式化表示来描述他们的相互关系。

不同意图识别问题中都有要被识别的意图倾向  $C$ 。如 Tang 等人<sup>[15]</sup>的情感极性识别研究, $C$ 对应需要五级的情感极性。在刘丹丹等人<sup>[37]</sup>的微博情感分类研究中, $C$ 对应喜好、安乐、惊奇、厌恶、悲哀、愤恨、恐惧。邓钊等人<sup>[38]</sup>的中文反语识别研究中, $C$ 则对应是否包含反讽。

其次是研究主体  $T$ ,它是行为发起者  $S$  的行为记录,可以认为他表达想法和情感的载体。另外一些场景下会有背景信息  $B$ ,对应所有有助于正确理解  $T$  的信息。譬如要研究讨论区上帖子的意图倾向,那么  $T$  就是帖子的内容,包括其中的文本内容、图片、文件附件等, $S$  则是帖子的发布者。而帖子所在讨论区的类型有助于定位帖子对应的领域,发布者的发布历史显示发布者的一些态度倾向,帖子下的评论从侧表反映主帖的内容,这些就是背景信息  $B$ ,都可能是理解帖子内容的提示。又以 Zahiri 等人<sup>[39]</sup>对电视剧台词的情感识别研究为例,那么  $T$  指电视剧中的台词, $S$  则是发出这段台词的对应角色, $B$  则是台词的上文,其中包含其他角

色正在谈论的内容，这些角色和发言者的关系是什么，说话的氛围如何等等，都能对台词的内容有更明确的定位。

意图识别假设对于任意一个研究样本  $t \in T$ ，在给定背景信息  $b \in B$ （或某些情况下假设与背景信息无关），其承载想法或情感必然存在对应的倾向  $c \in C$ 。意图识别首先要从样本主体和背景信息中分别提取出与识别目标相关的信息  $f_t$  和  $f_b$ ，即需要提出两个映射函数， $F_T$  和  $F_B$ ，满足  $f_t = F_T(t)$  和  $f_b = F_B(b)$ 。再进一步根据相关信息识别出其想法或情感倾向，即找出一个映射关系  $F_C$ ，使得  $c = F_C(f_t, f_b) = F_C(F_T(t), F_B(b))$ 。

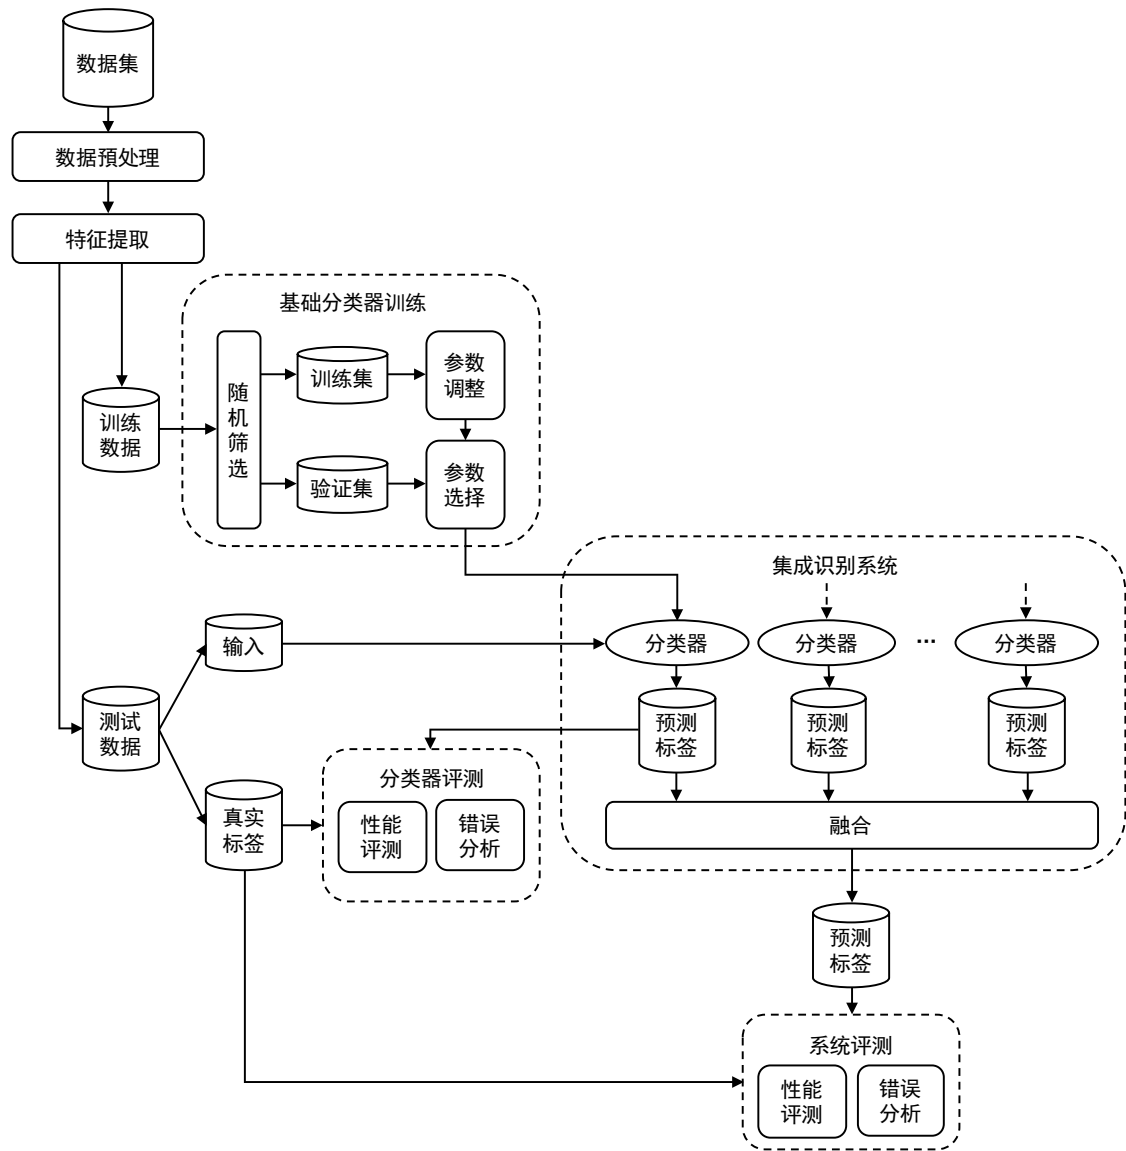


图 2.1 意图识别的研究框架



## 2.3 研究框架

在本小节，我们将根据前述的形式化表示给出一个意图识别的研究框架。由于在本论文的后续研究均面向英语社交媒体文本的分类问题，我们会针对此研究方法对框架进行细化，从原始文本的输入到最终识别目标的输出，理清其中每个步骤的功能和目的，给出一个集成系统的设计框架。针对不同的应用的场景，在后续实验章节中将给出具体的实现方案。

### 2.3.1 框架入口

图 2.1显示本文面向意图识别的研究框架。整个框架的输入是实验的数据集，数据集的每个样本包含三个元素，分别是研究的主体、背景信息和意图的倾向。参考前一小节的形式化表示，一个样本可以表示为  $\langle t, b, c \rangle \in T \times B \times C$ 。不论是训练数据或测试数据，他们都采用相同的数据预处理技术和特征提取技术来获取样本的特征，以用作分类器的输入，即透过  $F_T$  和  $F_B$  分别获取  $f_t = F_T(t)$  和  $f_b = F_B(b)$ 。

### 2.3.2 基础分类器

在特征提取完成后，识别模型的输入就准备好了。接下来首先对基础分类器进行研究和分析，比较不同模型和不同参数在对应问题上的整体性能。对于机器学习方法，在模型的训练过程中，需要将训练数据会分成训练集和验证集两个部分。训练集用于调整模型的参数，根据预先设计的损失函数计算模型当前的预测结果和实际标签的偏差，透过微分计算出参数的调整方向，并以一定的学习步长逐步迭代。由于以上训练过程在数学逻辑上是以达到训练集上的最优解来调整参数，会出现对训练样本过拟合的问题，因此会采用验证集来评估模型对训练集以外的样本的识别性能。在每一轮参数调整后计算当前模型在验证集上的性能指标，最后选择其中最优的一轮参数作为该次模型训练最终的参数。

除了分析不同模型在对应问题上的整体性能，透过对被分类器错误识别的样本进行观察，我们需要分析单个分类器的性能局限在哪，分类器对哪些类别的样本有更高的正确率或召回率，哪些样本之间容易出现混淆，或者在输入数据当中是否存在一些有关键信息的特征没有被成功提取。特别地意图识别的研究课题中，我们会关注数据集标签的正确性。在实验的过程中我们假设标签是正确，但有研究指出自动标注会引入噪声<sup>[27]</sup>，人工标注则难以避免地存在主观性。虽然对不同算法之间的性能比较影响不大，但对于技术水平的评估有其分析的价值。

### 2.3.3 集成识别系统

经过对基础分类器的分析后，我们对不同模型的识别性能有了深入的了解。为了进一步达到更好的性能，下一步是基于基础分类器研究集成识别系统的策略和设计。我们提出了一种集成系统的设计方案，结合多个模型相同的分类器的预测结果来作出最终判断，旨在只使用一种模型的基础上尽可能提升识别的性能，或针对特定的性能指标对整个系统的识别倾向进行调整。参考决策树，其识别过程可以认为是一系列的决策，每一步决策都建立在前一步的决策结果上，并且只关注原始问题中的子问题。类似地，我们提出的集成系统经过多次决策来对样本进行意图识别，第一步先由一个分类器或多个分类器的预测结果融合得到一个基础的预测结果，接下来的每一步需要先对前一步的混淆矩阵进行分析，根据哪些类别的样本被误判对指标的影响较大，设定一个子识别任务，从训练数据中筛选出相关的子集来训练新的基础分类器，得出针对该子识别任务的决策结果，决定是否修改上一步中的预测结果。这一方法的原理在于相同的模型在相同配置下的拟合能力是有限的，而子识别任务是原始问题的简化，模型可以专注于拟合一个局部问题，并对前一步的预测结果提出修改意见，起着补丁的作用。具体方法将在后续实验章节中给出详细说明。

同样地，我们需要分析集成系统的性能。在测试数据上，观察系统经过每一轮决策调整之后的识别性能变化，验证系统框架的设计是否满足假设。另外深入观察混淆矩阵的变化，分析各个子识别任务有效的原因，判断其适用和不适用的场景。

## 2.4 本章小结

在本章我们首先对意图识别给出统一的形式化表示，引出了其中涉及各个元素并描述他们的相互关系。然后描述了我们面向意图识别的研究框架，其中包括了两个研究重点。一是研究以不同算法得到的分类器对研究问题的整体性能，并作深入的分析，包括单个算法对不同类别样本的识别能力、比较不同算法在不同指标上的区别以理解他们的拟合倾向、观察被错误识别的样本并找出其原因等。二是研究基于基础分类器的集成系统，鉴于单个分类器的识别能力有限，我们提出了一个集成系统的设计方案，旨在结合多个基础分类器的预测结果来得出最终的判断，从而充分发挥一个数学模型的拟合能力，细节实现方法将在后续具体的应用场景中给出说明。

## 第3章 意图识别技术

### 3.1 本章引论

根据前一章中描述的研究框架，在本章中我们将针对每一个功能介绍对应的技术实现，其中包括文本预处理、词特征提取、分类算法、集成学习。对后续实验中使用的技术给出相对充分的说明，同时也会相关的技术给出概要的描述，以便于其他研究者在本论文未深入探索的方向作出拓展性的研究。

### 3.2 文本预处理

文本的预处理是所有面向文本的研究的第一步，其目的是为特征提取做好准备。良好的预处理策略可以在尽可能不掉失重要信息的情况下对样本数据进行简化，增加样本之间重复的模式，减轻模型对数据进行拟合的负担，同时更有效地找出数据之间的相互关系。错误的预处理策略会会掉失具有区分能力的信息，甚至产生具有误导性的样本。对于不同的语言，由于其天然的性质不同，预处理的方法也会各异，以下会重点介绍针对社交媒体上英语文本的预处理技术。

#### 3.2.1 分词

为了从文本提取词级别的特征，我们需要首先将句子切成多个词的序列。

虽然对于英语及大部分欧洲语言，空格隔开的字符必然属于不同的词组，但对于不以空格分隔词组的语言（如中文），分词的作用尤其重要。在某些情况下，分词的结果会影响对句子的理解，如将“乒乓球拍卖完了”切割成“乒乓球拍-卖-完-了”或“乒乓球-拍卖-完-了”，对主体应该是“乒乓球拍”还是“乒乓球”，动词应该是“卖”还是“拍卖”，仅凭字面意思无法确定发言者想表达的意思。特别地社交媒体平台上，新词不断的出现，要正确进行分词就有其独特的难点。而分词并不只针对语言中的单词，还针对标点符号或其他特征字符组成的有特殊语义或情感的字符组合，如现今社交媒体上普遍用多个字符拼接成颜文字，其中最常见的微笑的表情“:)”和伤心的表情“:(”，但如果在分词过程中把前者分割成“:”和“)”就会失去其所带的正向情感信息，这在短文本的情感识别中非常关键。

虽然利用空格和标点符号在大部分情况下可以完成对英语句子的分词，但在一些情况下，标点符号作用为词组的一部分而不是词组的分隔符，而在社交媒体上会有空格被省略的情况，以下是一些需要额外处理的情况<sup>[40][41]</sup>。一是带句号

的缩写，如“U.S.”，“.com”，句号应该作为词的一部分，或按句号切割“U.S.”将失去其语义。二是具有一定格式的带标点符号的词组，如电子邮箱地址（如 `example@email.com`）、时间（如 `Jan 6th`、`06/01/19`）、电话号码（如 `(123)456-7890`）、网页地址（如 `www.example.com`）等，而在大部分情况下，我们会优先关注这个字符串指的是什么类型的事物而不是细节，譬如将一个句子中的电子邮箱地址或电话号码作替换并不会改变其情感的表达，但识别出一个字符串对应的事情类型，并在清楚它对意图识别没有关联的情况下对其忽略是有意义的。第三种情况是附属词，如“`t`”对应“`not`”，只有正确识别“`’`”的作用才能识别出否定的意思，否则句子的意思将完全相反。值得注意的是，对社交媒体平台上的文本，除了以上在正规英语中会出现的情况，还有出现其他特殊情况，如“`Y!E!S!`”和“`N!O!`”。这需要对数据首先进行人工观察找出特殊的模式，再对语料库进行统计判断其出现频率，若出现频率较高则新增处理规则将对应模式做转换（如将“`Y!E!S!`”替换成“`YES!!!`”）或对问题无关的模式忽略（如国外的微博以“`RE:`”开头表示回复，并不包含任何情感）。

### 3.2.2 拼写修正

在处理较正式的文件时，我们一般可以默认其文本满足正规的语言语法，词汇基本都是正确的拼写或故意设计的新词（如杂志专栏作家首创针对英国退出欧盟首创单词“`Brexit`”）。不过在社交媒体上，拼写不符合传统英语的情况则非常普遍，这些情况可以分成三大类。

第一类是非刻意的拼写错误，由于社交媒体上的文本普遍是非正式的，用户不会刻意去保证文本的语言正确性，他们更关注于表达自己的想法、感情或其他意图。拼写修正技术一般基于统计的方法，对于一个不存在的词汇，尝试对其拼写进行有限次编辑，再评估编辑后的词在其上下文中出现的概率，最后选出可能性最高的一个词作替换。拼写修正技术已相当成熟地被应用于搜索引擎和手机键盘等应用中，读者可参考相关研究<sup>[42][43]</sup>了解其细节。

第二种情况是网络上常用的代替用词，如以“`thx`”、“`tnx`”代替“`thanks`”，以“`k`”代替“`ok`”，以“`cant`”代替“`can't`”。虽然这些用法没有被认可为标准用法，但由于方便而在网络上被传播开成功网民们都能理解的用词。对此应对方法有两种，一是人工建立映射表，把代替用词映射到标准的英语词汇，优点在于可以直接引用标准词汇的语义信息，但缺点是需要人工参与，特别是在网络上新用词不断出现的情况下需要持续的更新。另一种是不做处理，利用机器学习方法从大型语料库中自动学习出它的语义，优点在于省去了人工的部分，缺点在于单词的出现很稀疏，对语料库的依赖很强。

第三种情况是语气加强，如“yeeeees”，“AMAZING”，但对于这一类情况处理的重点不只在于转换成标准用词，而是根据具体的应用问题判断是否要保留这个词存在语气加强的这个信息，譬如在情感识别中，语气加强一般提示了此处的情感需要注意。Baziotis 等人<sup>[44]</sup>的做法是在单词前后添加标签示意，如“yeeeees”替换成“yes <enlongated>”，“AMAZING”替换成“amazing <allcaps>”。

### 3.2.3 规范化

pass

## 3.3 特征提取

pass

### 3.3.1 词嵌入

pass

### 3.3.2 词汇特征

### 3.3.3 句法特征

### 3.3.4 语义特征

### 3.3.5 基于人工神经网络

## 3.4 分类算法

pass

### 3.4.1 传统机器学习方法

### 3.4.2 深度学习方法

## 3.5 集成学习

pass

## 3.6 本章小结

pass

## 插图索引

图 1.1	Plutchik <sup>[4]</sup> 提出的情感轮模型 .....	2
图 1.2	Hugo <sup>[11]</sup> 的情感立方体模型 .....	3
图 1.3	引入多个领域信息的反讽识别神经网络模型, 引自 <sup>[28]</sup> .....	7
图 1.4	基于卷积神经网络的微博情感分类模型, 引自 <sup>[35]</sup> .....	8
图 2.1	意图识别的研究框架 .....	12

## 表格索引

## 公式索引

公式 A-1 .....	27
公式 A-2 .....	27



## 参考文献

- [1] Banerjee S, Dutta U. Detection of emotions in text: A survey: volume 03[M]. [S.l.: s.n.], 2015
- [2] Chatterjee A, Narahari K N, Joshi M, et al. Semeval-2019 task 3: Emocontext: Contextual emotion detection in text[C]//Proceedings of The 13th International Workshop on Semantic Evaluation (SemEval-2019). Minneapolis, Minnesota: [s.n.], 2019.
- [3] Alm C O, Dan R, Sproat R. Emotions from text: Machine learning for text-based emotion prediction[C]//Conference on Hlt/emnlp. [S.l.: s.n.], 2005.
- [4] Plutchik R, Kellerman H. Emotion: Theory, research and experience[J]. In Theories of emotion, 1980, 11: 399.
- [5] Ekman P. An argument for basic emotions[J]. Cognition & Emotion, 1992, 6(3-4): 169-200.
- [6] Russell J. A circumplex model of affect[J]. Journal of Personality and Social Psychology, 1980, 39: 1161-1178.
- [7] M. Bradley M, Greenwald M, C. Petry M, et al. Remembering pictures: Pleasure and arousal in memory[J]. Journal of experimental psychology. Learning, memory, and cognition, 1992, 18: 379-90.
- [8] Watson D, Tellegen A. Toward a consensual structure of mood[J]. Psychological bulletin, 1985, 98: 219-35.
- [9] Rubin D C, Talarico J M. A comparison of dimensional models of emotion: evidence from emotions, prototypical events, autobiographical memories, and words[J]. Memory, 2009, 17(8): 802-808.
- [10] Mehrabian A. Pleasure-arousal-dominance: A general framework for describing and measuring individual differences in temperament[J]. Current Psychology, 1996, 14(4): 261-292.
- [11] Hugo L. A new three-dimensional model for emotions and monoamine neurotransmitters[J]. Medical Hypotheses, 2012, 78(2): 341-348.
- [12] Mohammad S, Bravo-Marquez F, Salameh M, et al. Semeval-2018 task 1: Affect in tweets[C]//Proceedings of The 12th International Workshop on Semantic Evaluation. [S.l.: s.n.], 2018: 1-17.
- [13] Turney P D. Thumbs up or thumbs down?: semantic orientation applied to unsupervised classification of reviews[C]//Proceedings of the 40th annual meeting on association for computational linguistics. [S.l.]: Association for Computational Linguistics, 2002: 417-424.
- [14] Pang B, Lee L. A sentimental education: Sentiment analysis using subjectivity summarization based on minimum cuts[C]//Proceedings of the 42nd annual meeting on Association for Computational Linguistics. [S.l.]: Association for Computational Linguistics, 2004: 271.
- [15] Tang D, Qin B, Liu T. Learning semantic representations of users and products for document level sentiment classification[C]//Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 1: Long Papers): volume 1. [S.l.: s.n.], 2015: 1014-1023.

- [16] Khan A, Baharudin B, Khan K. Sentiment classification using sentence-level lexical based[J]. Trends in Applied Sciences Research, 2011, 6(10): 1141-1157.
- [17] Li Y, Lin Y, Zhang J, et al. Constructing domain-dependent sentiment lexicons automatically for sentiment analysis[J]. Information Technology Journal, 2013, 12(5): 990-996.
- [18] Dos Santos C, Gatti M. Deep convolutional neural networks for sentiment analysis of short texts[C]//Proceedings of COLING 2014, the 25th International Conference on Computational Linguistics: Technical Papers. [S.l.: s.n.], 2014: 69-78.
- [19] Che W, Zhao Y, Guo H, et al. Sentence compression for aspect-based sentiment analysis[J]. IEEE/ACM transactions on audio, speech, and language processing, 2015, 23(12): 2111-2124.
- [20] Wang Y, Huang M, Zhao L, et al. Attention-based lstm for aspect-level sentiment classification [C]//Proceedings of the 2016 conference on empirical methods in natural language processing. [S.l.: s.n.], 2016: 606-615.
- [21] Pontiki M, Galanis D, Pavlopoulos J, et al. Semeval-2014 task 4: Aspect based sentiment analysis [C]//Proceedings of The 8th International Workshop on Semantic Evaluation (SemEval-2014). [S.l.: s.n.], 2014: 27-35.
- [22] Tang D, Qin B, Liu T. Aspect level sentiment classification with deep memory network[J]. arXiv preprint arXiv:1605.08900, 2016.
- [23] Tsur O, Davidov D, Rappoport A. Icwsm—a great catchy name: Semi-supervised recognition of sarcastic sentences in online product reviews[C]//Fourth International AAAI Conference on Weblogs and Social Media. [S.l.: s.n.], 2010.
- [24] Davidov D, Tsur O, Rappoport A. Semi-supervised recognition of sarcastic sentences in twitter and amazon[C]//Proceedings of the fourteenth conference on computational natural language learning. [S.l.: Association for Computational Linguistics, 2010: 107-116.
- [25] Reyes A, Rosso P, Veale T. A multidimensional approach for detecting irony in twitter[J]. Language resources and evaluation, 2013, 47(1): 239-268.
- [26] Kunneman F, Liebrecht C, Van Mulken M, et al. Signaling sarcasm: From hyperbole to hashtag [J]. Information Processing & Management, 2015, 51(4): 500-509.
- [27] Littlestone N. Learning quickly when irrelevant attributes abound: A new linear-threshold algorithm[J]. Machine learning, 1988, 2(4): 285-318.
- [28] Poria S, Cambria E, Hazarika D, et al. A deeper look into sarcastic tweets using deep convolutional neural networks[J]. arXiv preprint arXiv:1610.08815, 2016.
- [29] Madhusudhanan S, Moorthi D M. A survey on sentiment analysis[J]. Indian Journal of Computer Science and Engineering, 2018, 9(2).
- [30] 谢丽星, 周明, 孙茂松. 基于层次结构的多策略中文微博情感分析和特征抽取[J]. 中文信息学报, 2012, 26(1): 73-84.
- [31] Go A, Huang L, Bhayani R. Twitter sentiment analysis[J]. Entropy, 2009, 17: 252.
- [32] Paltoglou G, Thelwall M. Twitter, myspace, digg: Unsupervised sentiment analysis in social media[J]. ACM Transactions on Intelligent Systems and Technology (TIST), 2012, 3(4): 66.
- [33] Khan FH, Bashir S, Qamar U. Tom: Twitter opinion mining framework using hybrid classification scheme[J]. Decision Support Systems, 2014, 57: 245-257.

- [34] Angiani G, Ferrari L, Fontanini T, et al. A comparison between preprocessing techniques for sentiment analysis in twitter.[C]//KDWeb. [S.l.: s.n.], 2016.
- [35] 张海涛, 王丹, 徐海玲, 等. 基于卷积神经网络的微博舆情情感分类研究[J]. 情报学报, 2018, 37: 695-702.
- [36] Van Hee C, Lefever E, Hoste V. Semeval-2018 task 3: Irony detection in english tweets[C]// Proceedings of The 12th International Workshop on Semantic Evaluation (SemEval-2018). [S.l.: s.n.], 2018: 39-50.
- [37] 刘丹丹, 邱恒清, 赵应丁. 基于 svm 的中文微博情感识别与分类研究[J]. 中国新通信, 2015, 17(21): 48-51.
- [38] 邓钊, 贾修一, 陈家骏. 面向微博的中文反语识别研究[J]. 计算机工程与科学, 2015, 37(12): 2312-2317.
- [39] Zahiri S M, Choi J D. Emotion detection on tv show transcripts with sequence-based convolutional neural networks[Z]. [S.l.: s.n.], 2017.
- [40] Jackson P, Moulinier I. Natural language processing for online applications[M]. [S.l.]: John Benjamins, 2007
- [41] Mitkov R. The oxford handbook of computational linguistics[M]. [S.l.]: Oxford University Press, 2004
- [42] Ahmed F, Luca E W D, Nürnberger A. Revised n-gram based automatic spelling correction tool to improve retrieval effectiveness[J]. Polibits, 2009(40): 39-48.
- [43] Nejja M, Yousfi A. The context in automatic spell correction[J]. Procedia Computer Science, 2015, 73: 109-114.
- [44] Baziotis C, Pelekis N, Doukeridis C. Datastories at semeval-2017 task 4: Deep lstm with attention for message-level and topic-based sentiment analysis[C]//Proceedings of the 11th International Workshop on Semantic Evaluation (SemEval-2017). Vancouver, Canada: Association for Computational Linguistics, 2017: 747-754.
- [45] 薛瑞尼. THUTHESIS: 清华大学学位论文模板[EB/OL]. 2017. <https://github.com/xueruini/thuthesis>.

## 致 谢

衷心感谢导师 xxx 教授和物理系 xxx 副教授对本人的精心指导。他们的言传身教将使我终生受益。

在美国麻省理工学院化学系进行九个月的合作研究期间，承蒙 xxx 教授热心指导与帮助，不胜感激。感谢 xx 实验室主任 xx 教授，以及实验室全体老师和同学们的热情帮助和支持！本课题承蒙国家自然科学基金资助，特此致谢。

感谢 L<sup>A</sup>T<sub>E</sub>X 和 THU<sub>THE</sub>SIS<sup>[45]</sup>，帮我节省了不少时间。

## 声 明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果。尽我所知，除文中已经注明引用的内容外，本学位论文的研究成果不包含任何他人享有著作权的内容。对本论文所涉及的研究工作做出贡献的其他个人和集体，均已在文中以明确方式标明。

签 名：\_\_\_\_\_ 日 期：\_\_\_\_\_

## 附录 A 外文资料原文

The title of the English paper

**Abstract:** As one of the most widely used techniques in operations research, *mathematical programming* is defined as a means of maximizing a quantity known as *objective function*, subject to a set of constraints represented by equations and inequalities. Some known subtopics of mathematical programming are linear programming, nonlinear programming, multiobjective programming, goal programming, dynamic programming, and multilevel programming<sup>[1]</sup>.

It is impossible to cover in a single chapter every concept of mathematical programming. This chapter introduces only the basic concepts and techniques of mathematical programming such that readers gain an understanding of them throughout the book<sup>[2,3]</sup>.

### A.1 Single-Objective Programming

The general form of single-objective programming (SOP) is written as follows,

$$\begin{cases} \max f(x) \\ \text{subject to:} \\ g_j(x) \leq 0, \quad j = 1, 2, \dots, p \end{cases} \quad (123)$$

which maximizes a real-valued function  $f$  of  $x = (x_1, x_2, \dots, x_n)$  subject to a set of constraints.

**Definition A.1:** In SOP, we call  $x$  a decision vector, and  $x_1, x_2, \dots, x_n$  decision variables. The function  $f$  is called the objective function. The set

$$S = \{x \in \mathbb{R}^n \mid g_j(x) \leq 0, j = 1, 2, \dots, p\} \quad (456)$$

is called the feasible set. An element  $x$  in  $S$  is called a feasible solution.

Definition A.2: A feasible solution  $x^*$  is called the optimal solution of SOP if and only if

$$f(x^*) \geq f(x) \quad (\text{A-1})$$

for any feasible solution  $x$ .

One of the outstanding contributions to mathematical programming was known as the Kuhn-Tucker conditions A-2. In order to introduce them, let us give some definitions. An inequality constraint  $g_j(x) \leq 0$  is said to be active at a point  $x^*$  if  $g_j(x^*) = 0$ . A point  $x^*$  satisfying  $g_j(x^*) \leq 0$  is said to be regular if the gradient vectors  $\nabla g_j(x)$  of all active constraints are linearly independent.

Let  $x^*$  be a regular point of the constraints of SOP and assume that all the functions  $f(x)$  and  $g_j(x)$ ,  $j = 1, 2, \dots, p$  are differentiable. If  $x^*$  is a local optimal solution, then there exist Lagrange multipliers  $\lambda_j$ ,  $j = 1, 2, \dots, p$  such that the following Kuhn-Tucker conditions hold,

$$\begin{cases} \nabla f(x^*) - \sum_{j=1}^p \lambda_j \nabla g_j(x^*) = 0 \\ \lambda_j g_j(x^*) = 0, \quad j = 1, 2, \dots, p \\ \lambda_j \geq 0, \quad j = 1, 2, \dots, p. \end{cases} \quad (\text{A-2})$$

If all the functions  $f(x)$  and  $g_j(x)$ ,  $j = 1, 2, \dots, p$  are convex and differentiable, and the point  $x^*$  satisfies the Kuhn-Tucker conditions (A-2), then it has been proved that the point  $x^*$  is a global optimal solution of SOP.

### A.1.1 Linear Programming

If the functions  $f(x)$ ,  $g_j(x)$ ,  $j = 1, 2, \dots, p$  are all linear, then SOP is called a *linear programming*.

The feasible set of linear is always convex. A point  $x$  is called an extreme point of convex set  $S$  if  $x \in S$  and  $x$  cannot be expressed as a convex combination of two points in  $S$ . It has been shown that the optimal solution to linear programming corresponds to an extreme point of its feasible set provided that the feasible set  $S$  is bounded. This fact is the basis of the *simplex algorithm* which was developed by Dantzig as a very efficient method for solving linear programming.

Table 1 This is an example for manually numbered table, which would not appear in the list of tables

Network Topology		# of nodes	# of clients			Server
GT-ITM	Waxman Transit-Stub	600	2%	10%	50%	Max. Connectivity
Inet-2.1		6000				
Xue	Rui	Ni	THUThESIS			
	ABCDEF					

Roughly speaking, the simplex algorithm examines only the extreme points of the feasible set, rather than all feasible points. At first, the simplex algorithm selects an extreme point as the initial point. The successive extreme point is selected so as to improve the objective function value. The procedure is repeated until no improvement in objective function value can be made. The last extreme point is the optimal solution.

#### A.1.2 Nonlinear Programming

If at least one of the functions  $f(x), g_j(x), j = 1, 2, \dots, p$  is nonlinear, then SOP is called a *nonlinear programming*.

A large number of classical optimization methods have been developed to treat special-structural nonlinear programming based on the mathematical theory concerned with analyzing the structure of problems.



Figure 1 This is an example for manually numbered figure, which would not appear in the list of figures

Now we consider a nonlinear programming which is confronted solely with maximizing a real-valued function with domain  $\mathcal{R}^n$ . Whether derivatives are available or not, the usual strategy is first to select a point in  $\mathcal{R}^n$  which is thought to be the most likely place where the maximum exists. If there is no information available on which to base such a selection, a point is chosen at random. From this first point an attempt is made to construct a sequence of points, each of which yields an improved objective function value over its predecessor. The next point to be added to the sequence is chosen by analyzing the behavior of the function at the previous points. This construction continues until some



termination criterion is met. Methods based upon this strategy are called *ascent methods*, which can be classified as *direct methods*, *gradient methods*, and *Hessian methods* according to the information about the behavior of objective function  $f$ . Direct methods require only that the function can be evaluated at each point. Gradient methods require the evaluation of first derivatives of  $f$ . Hessian methods require the evaluation of second derivatives. In fact, there is no superior method for all problems. The efficiency of a method is very much dependent upon the objective function.

### A.1.3 Integer Programming

*Integer programming* is a special mathematical programming in which all of the variables are assumed to be only integer values. When there are not only integer variables but also conventional continuous variables, we call it *mixed integer programming*. If all the variables are assumed either 0 or 1, then the problem is termed a *zero-one programming*. Although integer programming can be solved by an *exhaustive enumeration* theoretically, it is impractical to solve realistically sized integer programming problems. The most successful algorithm so far found to solve integer programming is called the *branch-and-bound enumeration* developed by Balas (1965) and Dakin (1965). The other technique to integer programming is the *cutting plane method* developed by Gomory (1959).

*Uncertain Programming* (BaoDing Liu, 2006.2)

## References

*NOTE: These references are only for demonstration. They are not real citations in the original text.*

- [1] Donald E. Knuth. The  $\text{\TeX}$ book. Addison-Wesley, 1984. ISBN: 0-201-13448-9
- [2] Paul W. Abrahams, Karl Berry and Kathryn A. Hargreaves.  $\text{\TeX}$  for the Impatient. Addison-Wesley, 1990. ISBN: 0-201-51375-7
- [3] David Salomon. The advanced  $\text{\TeX}$ book. New York : Springer, 1995. ISBN:0-387-94556-3

## 附录 B 外文资料的调研阅读报告或书面翻译

### 英文资料的中文标题

**摘要：**本章为外文资料翻译内容。如果有摘要可以直接写上来，这部分好像没有明确的规定。

### B.1 单目标规划

北冥有鱼，其名为鲲。鲲之大，不知其几千里也。化而为鸟，其名为鹏。鹏之背，不知其几千里也。怒而飞，其翼若垂天之云。是鸟也，海运则将徙于南冥。南冥者，天池也。

$$p(y|\mathbf{x}) = \frac{p(\mathbf{x}, y)}{p(\mathbf{x})} = \frac{p(\mathbf{x}|y)p(y)}{p(\mathbf{x})} \quad (123)$$

吾生也有涯，而知也无涯。以有涯随无涯，殆已！已而为知者，殆而已矣！为善无近名，为恶无近刑，缘督以为经，可以保身，可以全生，可以养亲，可以尽年。

#### B.1.1 线性规划

庖丁为文惠君解牛，手之所触，肩之所倚，足之所履，膝之所倚，砉然响然，奏刀騞然，莫不中音，合于桑林之舞，乃中经首之会。

表 1 这是手动编号但不出现在索引中的一个表格例子

Network Topology		# of nodes	# of clients			Server
GT-ITM	Waxman Transit-Stub	600	2%	10%	50%	Max. Connectivity
Inet-2.1		6000				
Xue	Rui	Ni	THUThESIS			
	ABCDEF					

文惠君曰：“嘻，善哉！技盖至此乎？”庖丁释刀对曰：“臣之所好者道也，进乎技矣。始臣之解牛之时，所见无非全牛者；三年之后，未尝见全牛也；方今之时，臣以神遇而不以目视，官知止而神欲行。依乎天理，批大郤，导大窾，因其固然。技经肯綮之未尝，而况大瓠乎！良庖岁更刀，割也；族庖月更刀，折也；今臣之刀十九年矣，所解数千牛矣，而刀刃若新发于硎。彼节者有间而刀刃者无厚，以无厚

入有间，恢恢乎其于游刃必有余地矣。是以十九年而刀刃若新发于硎。虽然，每至于族，吾见其难为，怵然为戒，视为止，行为迟，动刀甚微，謦然已解，如土委地。提刀而立，为之而四顾，为之踌躇满志，善刀而藏之。”

文惠君曰：“善哉！吾闻庖丁之言，得养生焉。”

### B.1.2 非线性规划

孔子与柳下季为友，柳下季之弟名曰盗跖。盗跖从卒九千人，横行天下，侵暴诸侯。穴室枢户，驱人牛马，取人妇女。贪得忘亲，不顾父母兄弟，不祭先祖。所过之邑，大国守城，小国入保，万民苦之。孔子谓柳下季曰：“夫为人父者，必能诏其子；为人兄者，必能教其弟。若父不能诏其子，兄不能教其弟，则无贵父子兄弟之亲矣。今先生，世之才士也，弟为盗跖，为天下害，而弗能教也，丘窃为先生羞之。丘请为先生往说之。”



图 1 这是手动编号但不出现索引中的图片的例子

柳下季曰：“先生言为人父者必能诏其子，为人兄者必能教其弟，若子不听父之诏，弟不受兄之教，虽今先生之辩，将奈之何哉？且跖之为人也，心如涌泉，意如飘风，强足以距敌，辩足以饰非。顺其心则喜，逆其心则怒，易辱人以言。先生必无往。”

孔子不听，颜回为驭，子贡为右，往见盗跖。

### B.1.3 整数规划

盗跖乃方休卒徒大山之阳，脍人肝而脯之。孔子下车而前，见谒者曰：“鲁人孔丘，闻将军高义，敬再拜谒者。”谒者入通。盗跖闻之大怒，目如明星，发上指冠，曰：“此夫鲁国之巧伪人孔丘非邪？为我告之：尔作言造语，妄称文、武，冠枝木之冠，带死牛之胁，多辞缪说，不耕而食，不织而衣，摇唇鼓舌，擅生是非，以迷天下之主，使天下学士不反其本，妄作孝弟，而侥幸于封侯富贵者也。子之罪大极重，疾走归！不然，我将以子肝益昼脯之膳。”

## 附录 C 其它附录

前面两个附录主要是给本科生做例子。其它附录的内容可以放到这里，当然如果你愿意，可以把这部分也放到独立的文件中，然后将其 `\input` 到主文件中。

## 个人简历、在学期间发表的学术论文与研究成果

### 个人简历

xxxx 年 xx 月 xx 日出生于 xx 省 xx 县。

xxxx 年 9 月考入 xx 大学 xx 系 xx 专业, xxxx 年 7 月本科毕业并获得 xx 学士学位。

xxxx 年 9 月免试进入 xx 大学 xx 系攻读 xx 学位至今。

### 发表的学术论文

- [1] Yang Y, Ren T L, Zhang L T, et al. Miniature microphone with silicon- based ferroelectric thin films. Integrated Ferroelectrics, 2003, 52:229-235. (SCI 收录, 检索号:758FZ.)
- [2] 杨轶, 张宁欣, 任天令, 等. 硅基铁电微声学器件中薄膜残余应力的研究. 中国机械工程, 2005, 16(14):1289-1291. (EI 收录, 检索号:0534931 2907.)
- [3] 杨轶, 张宁欣, 任天令, 等. 集成铁电器件中的关键工艺研究. 仪器仪表学报, 2003, 24(S4):192-193. (EI 源刊.)
- [4] Yang Y, Ren T L, Zhu Y P, et al. PMUTs for handwriting recognition. In press. (已被 Integrated Ferroelectrics 录用. SCI 源刊.)
- [5] Wu X M, Yang Y, Cai J, et al. Measurements of ferroelectric MEMS microphones. Integrated Ferroelectrics, 2005, 69:417-429. (SCI 收录, 检索号:896KM)
- [6] 贾泽, 杨轶, 陈兢, 等. 用于压电和电容微麦克风的体硅腐蚀相关研究. 压电与声光, 2006, 28(1):117-119. (EI 收录, 检索号:06129773469)
- [7] 伍晓明, 杨轶, 张宁欣, 等. 基于 MEMS 技术的集成铁电硅微麦克风. 中国集成电路, 2003, 53:59-61.

### 研究成果

- [1] 任天令, 杨轶, 朱一平, 等. 硅基铁电微声学传感器畴极化区域控制和电极连接的方法: 中国, CN1602118A. (中国专利公开号)

- [2] Ren T L, Yang Y, Zhu Y P, et al. Piezoelectric micro acoustic sensor based on ferroelectric materials: USA, No.11/215, 102. (美国发明专利申请号)

综合论文训练记录表

学生姓名		学号		班级	
论文题目					
主要内容以及进度安排	<div>指导教师签字：_____</div> <div>考核组组长签字：_____</div> <div>年      月      日</div>				
中期考核意见	<div>考核组组长签字：_____</div> <div>年      月      日</div>				

指导教师评语	<div>指导教师签字：_____</div> <div>年      月      日</div>
评阅教师评语	<div>评阅教师签字：_____</div> <div>年      月      日</div>
答辩小组评语	<div>答辩小组组长签字：_____</div> <div>年      月      日</div>

总成绩：\_\_\_\_\_

教学负责人签字：\_\_\_\_\_

年      月      日